

2026 中国高校计算机大赛—人工智能创意赛

鸿蒙赛道作品说明文档（初赛）

参赛学校：同济大学

团队名称：微软大战代码

作品名称：智调鸿枢：面向鸿蒙应用生态的端侧 AI 感知调度中间件

赛题方向：操作系统智能创新

联系人（队长）：方鹭洋

联系电话（队长）：18856857376

2026 中国高校计算机大赛—人工智能创意赛

参赛团队信息表

作品名称	智调鸿枢：面向鸿蒙应用生态的端侧 AI 感知调度中间件							
团队名称	微软大战代码							
参赛学校	同济大学							
参赛赛题方向	☐ 应用创新 ☐ Agent 创新 ☐ 用户体验创新 ☒ 操作系统智能创新							
团队队员基本信息								
姓名及学号	学校全称	院（系）全称	专业全称	年级	毕业时间	联系电话	邮箱	团队分工
方鹭洋 2454329	同济大学					18856857376		
李一凡 2454326	同济大学					19905688857		
团队指导教师信息（指导老师须与队长同校）								
姓名	院（系）全称	职称	研究方向		联系电话	联系邮箱		
团队成员优势描述								
团队具备调度原理设计、HarmonyOS 工程实现、组合状态测试与技术材料固化能力，能够围绕任务优先级、设备约束和执行计划开展交叉复核，形成从设计、实现到验证的完整协作闭环。								

《智调鸿枢：面向鸿蒙应用生态的端侧 AI 感知调度中间件》作品原创性声明

郑重声明：承诺本参赛队伍报名信息真实有效；呈交的参赛作品相关资料以及所完成的作品实物等相关成果，是本团队独立进行研究工作所取得的成果，除文中已经注明引用的内容外，本作品说明文档不包含任何其他个人或集体已经发表或撰写过的作品成果，不侵犯任何第三方的知识产权或其他权利。本声明的法律结果由本参赛队承担。

参赛队员签名（团队全部成员）：

日期： 年 月 日

指导老师审核签名：

日期： 年 月 日

（注：本页签名可以打印纸质文件后签名，提供扫描件；或者使用电子签名。不论哪种方式，需保证页面内容完整、字迹清晰，请与本项目作品说明文档作为同一文档提交。）

一、创意描述

融合系统状态与任务语义的可解释端侧 AI 自适应调度中间件

二、技术方案

2.1 设计目标

智调鸿枢面向 HarmonyOS 应用层的端侧 AI 负载，在不修改系统内核、无需 root 权限的条件下，将任务语义、系统资源和近期执行反馈统一映射为可解释执行计划。购物助手用于验证图片与文字 Embedding、意图推理、商品检索和后台索引等不同负载，调度能力本身不依赖具体业务页面。

2.2 分层架构与技术路线

层级	主要职责	解耦接口
状态感知层	采集电量、充电、热等级、CPU、内存、前后台、队列和近期时延	统一 DeviceState 及 REAL/MIXED/INJECTED 来源
任务画像层	描述能力标识、任务类型、精度偏好、时延预算及端/云位置	TaskProfile 与可注册能力画像
决策控制层	执行极端安全保护、多维效用计算、模式偏置和按能力键防震荡	ExecutionPlan、原因码与策略版本
执行观测层	管理优先队列、1/2/4 线程档位、执行器、取消、超时、暂停/恢复和指标	HAR 公共 API、执行器注册与日志回调

技术路线为：系统 API 采样→任务能力画像→极端安全约束判定→多维效用计算→固定模式偏置或自适应映射→按能力键防震荡→后端与线程配置→优先队列执行→原因码和窗口指标回传。

2.3 优先级评分的确定

任务规范基础分采用 $B=35R+25U+20Q+20N$ 。R、U、Q、N 均归一化至 $[0, 1]$ ，依次表示截止期严格度、前台阻塞程度、降档质量损失和不可延后程度。35/25/20/20 是结合实时调度截止期思想、移动端 AI 准确率—资源权衡研究及任务走查形成的工程风险权重。镜头实时预览、图片主体框选、图片 Embedding、意图推理、文字 Embedding/本地检索和后台索引的规范分依次为 98、92、88、82、68 和 30。上述分数是专家规范量表，不是决策树或运行日志自动拟合结果。

2.4 运行时调度模型

提交版首先计算任务分 $S_{task}=0.42r+0.24p+0.20a+0.14w_{latency}$ ，其中 r 为能力画像先验，p 为任务类型权重，a 为精度偏好，w_latency 为时延紧迫度；再计算 $S=S_{task} \times f_b \times f_t \times f_q \times f_m \times f_r$ ，五个缩放因子分别表示电池、热状态、队列、内存和近期时延反馈。 $S \geq 0.70$ 映射为高精度/4 线程， $0.30 \leq S < 0.70$ 映射为均衡/2 线程， $S < 0.30$ 映射为轻量/1 线程。仅严重过热、低电量未充电和内存临界采用硬保护，其余组合状态由连续效用模型决策；固定高性能和固定省电只施加倾向，不取消安全与资源约束。

2.5 轻量模型训练与校准设计

（1）真机采样：跨设备组合任务类型、SOC、充电、温度、队列、内存、近期时延和可用后端，记录计划与真实结果，并保留设备、模型和状态来源。

（2）标签构建：以当前可解释效用模型作为教师策略，结合基准实验，最小化截止期违约、能耗、热暴露、质量损失和队列不公平的综合代价。

（3）分组训练：按设备与场景分组划分训练、验证和测试集，训练限深决策树或单调线性替代模型，避免相邻样本泄漏。

（4）压缩导出：对模型剪枝、定点量化，将树路径或权重表导出为 ArkTS Tree-to-Code，同时保留原因码和极端安全保护。

（5）留出验证：在未参与训练的设备、任务和组合状态上，对比固定高性能、固定省电与自适应策略；运行期只做轻量校正，周期性离线再训练。

当前提交版已运行可解释教师策略并完成组合场景阈值校准；统计学习替代模型属于上述离线训练路径，文档不将尚未完成的多机型真机训练表述为既成结果。

2.6 核心创新与优势

（1）任务语义与系统状态联合建模，使同一设备状态下的图片、文字和后台任务获得不同计划。

（2）仅在极端条件使用硬保护，其余状态由连续效用模型与模式偏置共同决定，支持电量、温度、队列和内存的组合决策。

（3）独立 HAR 实现状态适配、策略、队列、执行器和业务界面解耦，任务画像与执行器均可注册，便于迁移到其他 HarmonyOS 端侧 AI 应用。

（4）状态恶化即时降档、稳定恢复后延迟升档，并按能力键隔离历史，降低策略抖动和跨任务污染。

（5）每次调度输出原因码、状态来源、策略版本和运行指标，形成从输入、计划、执行到结果的可解释证据链。

三、介绍文档

端侧 AI 应用通常采用固定模型、固定线程和静态后端配置，难以在交互时延、识别质量、能耗、热稳定性与后台吞吐之间持续平衡。本作品面向 HarmonyOS 应用层构建可复用的 AI 感知调度中间件“智调鸿枢”，在不修改系统内核、无需 root 权限的前提下，通过公开 API 采集电量、充电状态、热等级、CPU 与内存信息、应用前后台状态，并结合任务类型、能力画像、精度偏好、时延预算、队列深度及近期执行反馈形成统一决策输入。中间件输出高精度、均衡、轻量三档模型配置，1/2/4 线程档位、可用后端偏好、任务优先级，以及入队、限流、暂停、恢复或拒绝等动作。严重过热、低电量未充电和内存临界等条件采用确定性安全保护，其余电量、温度、队列和内存组合由连续效用模型分析；固定高性能与固定省电模式仅施加策略倾向，不绕过安全边界和资源约束。任务规范基础分依据实时性、前台阻塞程度、降档质量损失和不可延后程度构建 100 分专家量表；运行时效用分再乘以电池、热、队列、内存和近期时延因子，避免将规范分误述为训练结果。提交版采用可解释加权效用模型作为轻量教师策略，并设计跨设备真机采样、综合代价标注、按设备与场景分组、限深模型训练、剪枝量化、Tree-to-Code 导出及留出设备验证流程，形成可复现路径。系统采用按能力键隔离的防震荡机制，状态恶化时即时降档，稳定恢复后延迟升档，防止相邻任务历史相互污染。每次调度均输出原因码、状态来源、策略版本、任务生命周期和窗口指标，形成从状态采集、计划生成、队列执行到结果反馈的可解释证据链。调度能力以独立 HAR 封装，状态适配器、策略、优先队列、执行器与业务界面相互解耦，任务画像和执行器均可注册替换，降低迁移和二次集成成本。购物助手仅作为图片与文字 Embedding、意图推理、商品检索和后台索引等异构负载的验证载体，中间件可复用于智能相册、文档检索、可穿戴分析及其他 HarmonyOS 端侧 AI 应用。

3.1 应用价值与推广前景

中间件适用于本地视觉识别、语音与文本编码、智能相册、文档检索和可穿戴健康分析等需要在交互质量与设备资源间动态权衡的 HarmonyOS 应用。接入方只需提供任务画像与执行器，不必重复开发电量、温控、排队和指标系统；通过 HAR 版本化接口可逐步替换业务模型、后端实现和离线蒸馏策略。

3.2 能力边界

本项目不修改 OpenHarmony/HarmonyOS 内核，不声称直接控制系统级调度器。GPU、NPU 或 NNRT 只有在公开接口可用、执行器初始化成功并完成同模型验证后才进入可用后端集合；未探测时使用 CPU。云端大模型为可选增强，不构成本地检索与调度演示的前置条件。

四、参考文献

- [1] Liu C. L., Layland J. W. Scheduling Algorithms for Multiprogramming in a Hard-Real-Time Environment. Journal of the ACM, 1973, 20(1): 46-61.
- [2] Han S., et al. MCDNN: An Approximation-Based Execution Framework for Deep Stream Processing Under Resource Constraints. MobiSys, 2016.
- [3] Kang Y., et al. Neurosurgeon: Collaborative Intelligence Between the Cloud and Mobile Edge. ASPLOS, 2017.